Độ trễ native Decision API

474 request hợp lệ/model · warmup được tách riêng

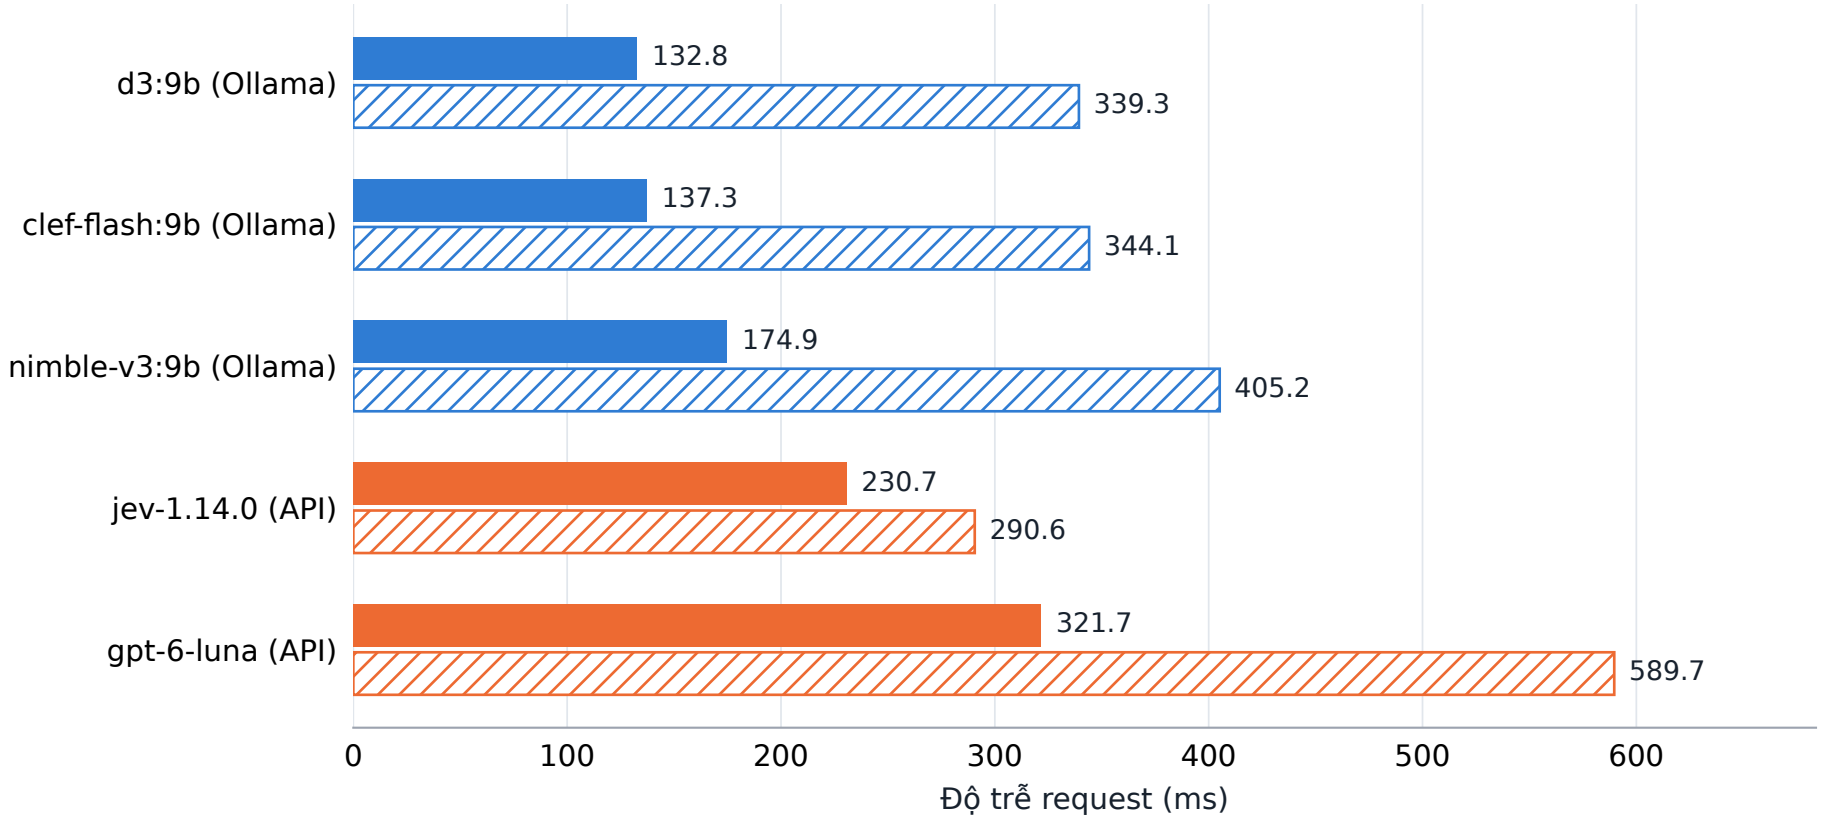

Thanh đặc: p50; thanh gạch: p95. Đây là phân vị độ trễ, không phải khoảng tin cậy.
API có độ trễ mạng từ Colab; các nhà cung cấp được chạy trong các phiên nối tiếp.