Tài nguyên GPU quan sát

Ba cấu hình Ollama Q8_0 trên A100 80 GB

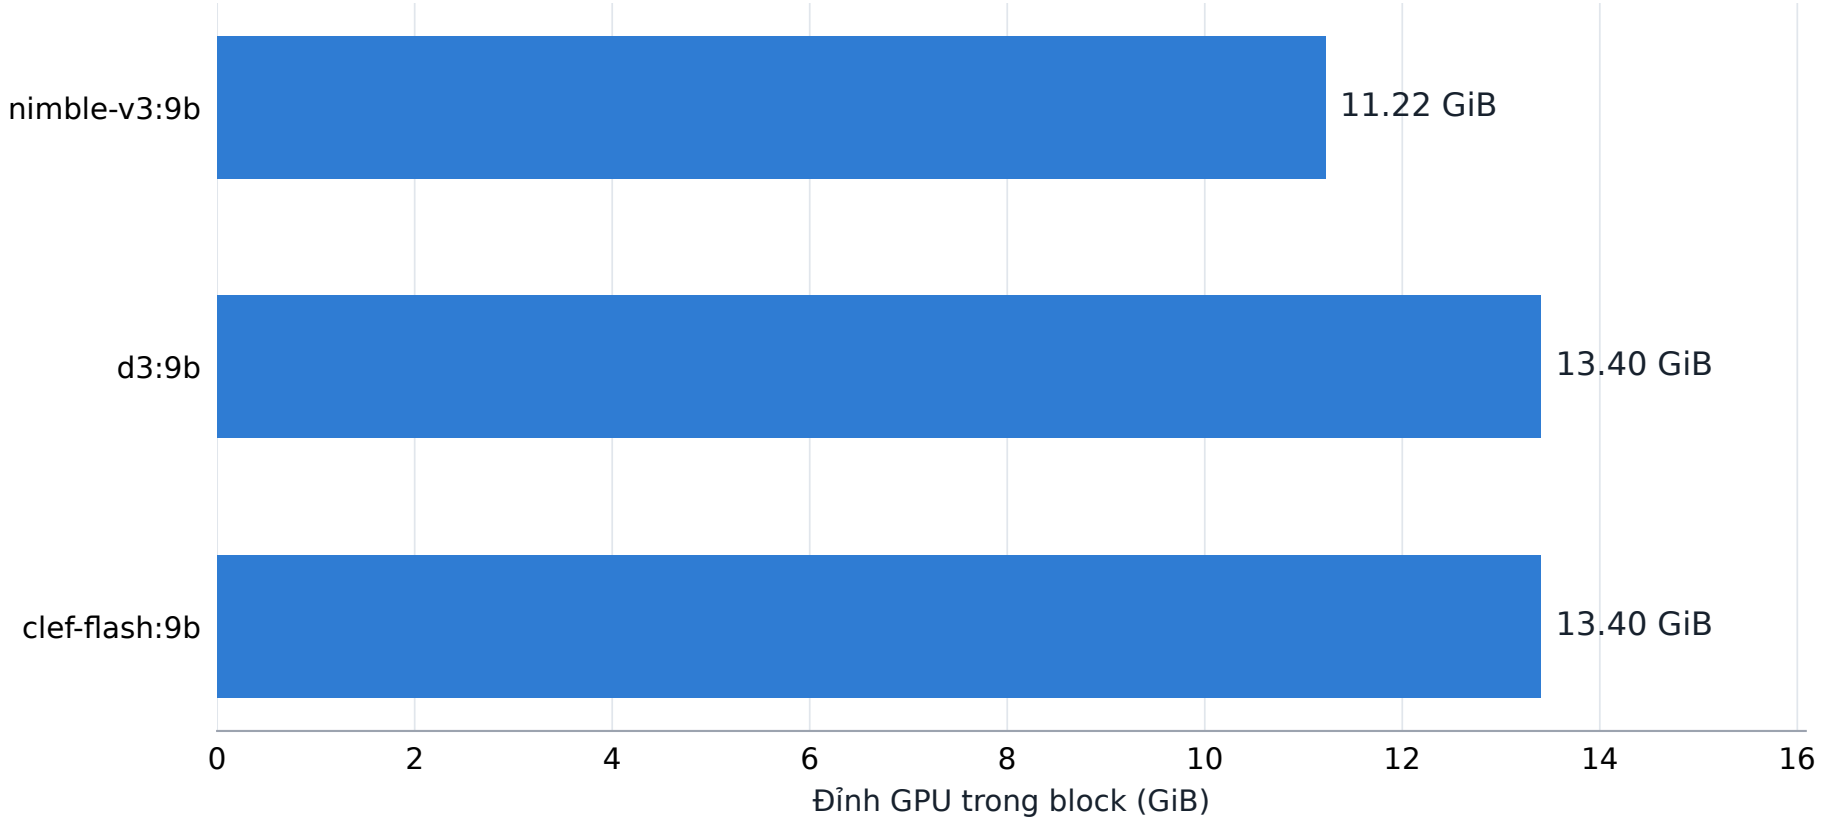

Cực đại nvidia-smi lấy mẫu trong block, có cả warmup/cache; không phải riêng kích thước trọng số.
Không quan sát VRAM phía nhà cung cấp API; dữ liệu thiếu không được vẽ thành số 0.