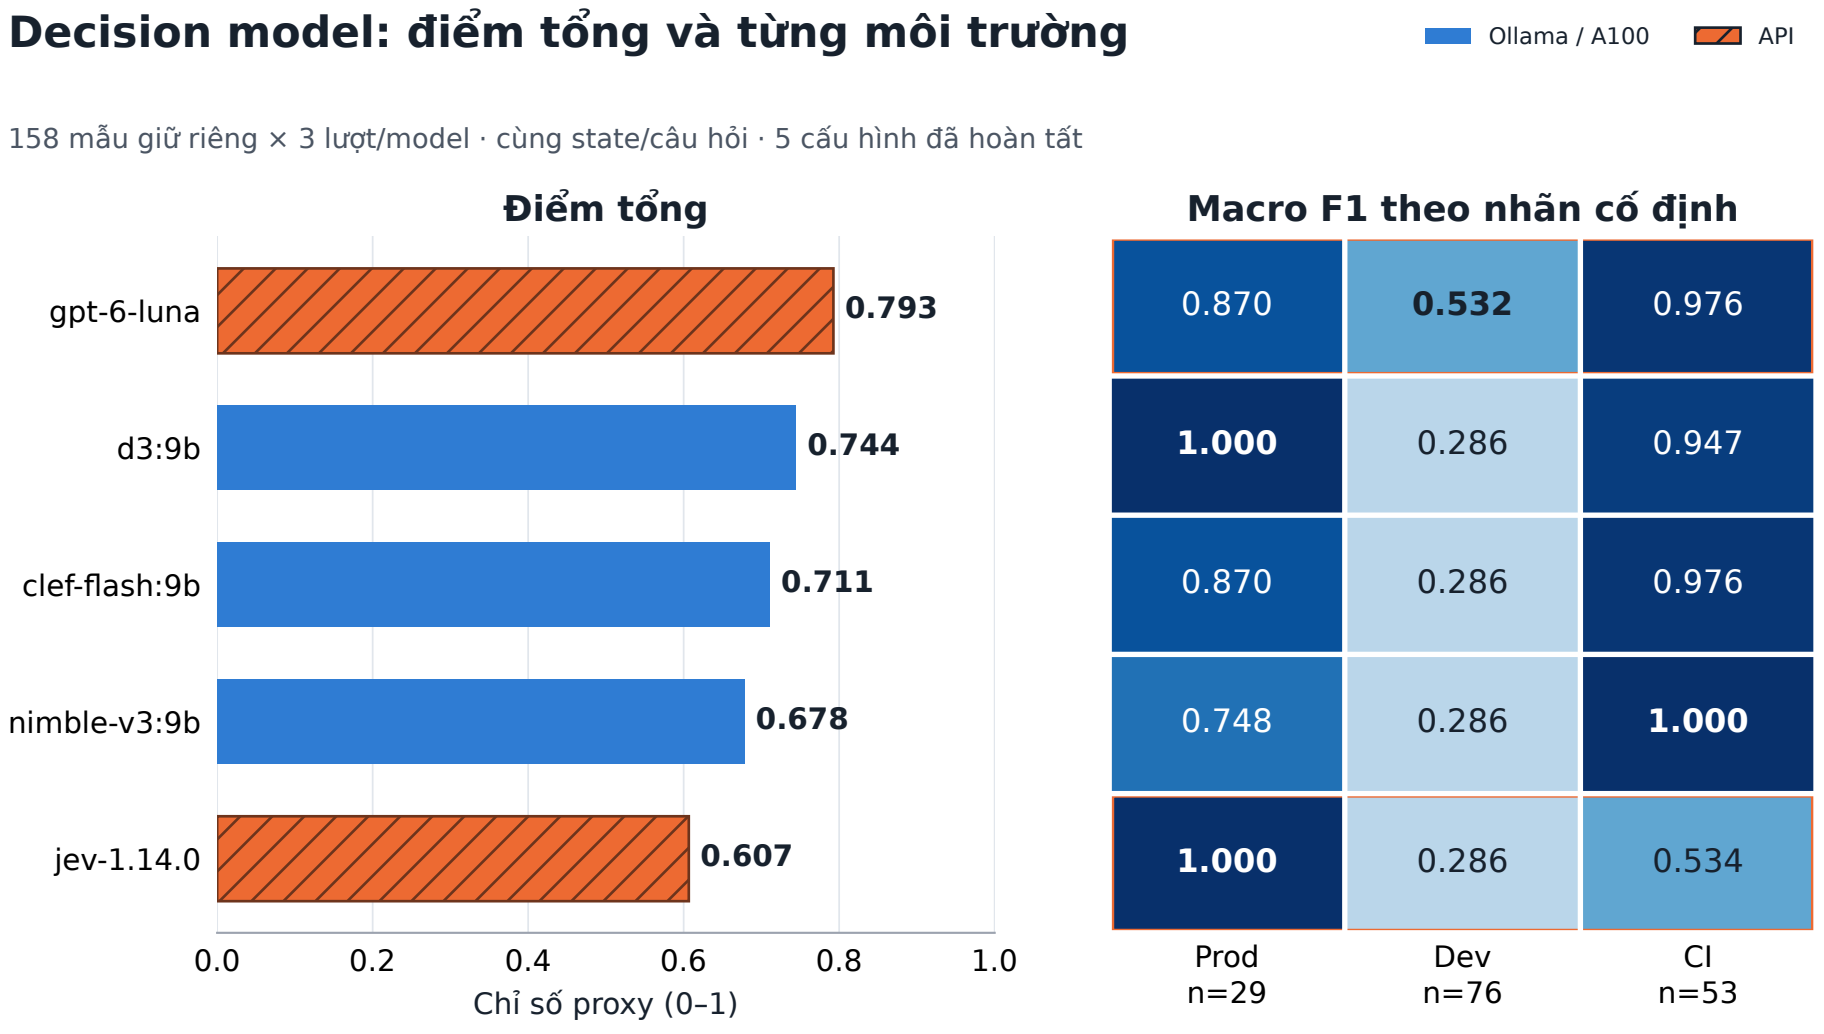
Decision model: điểm tổng và từng môi trường

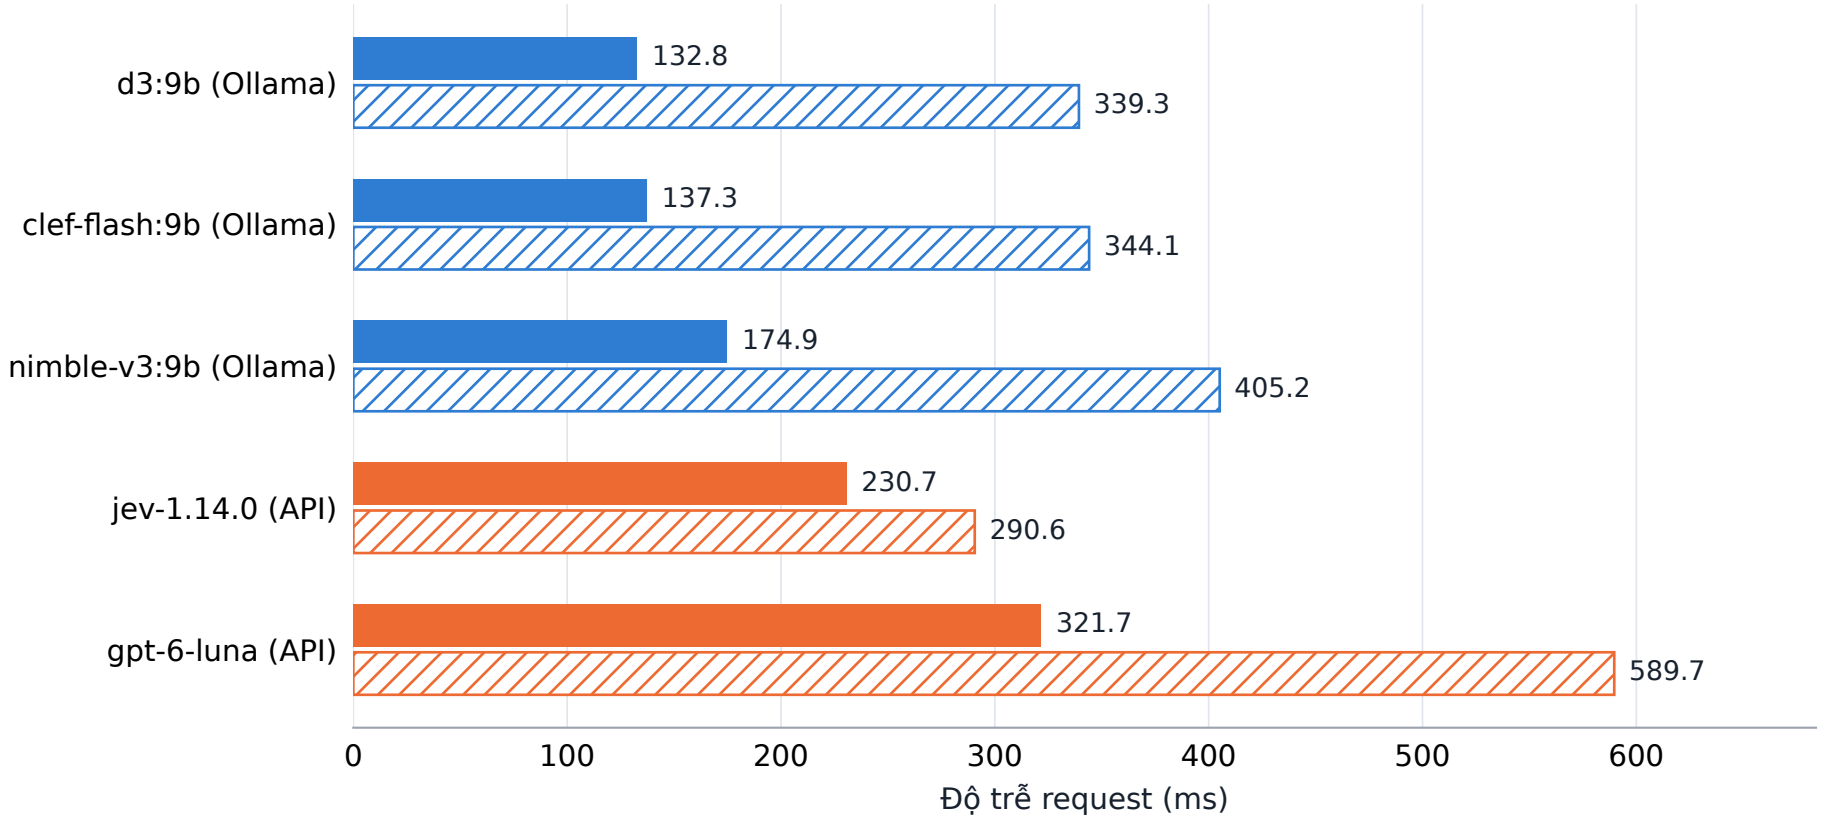
158 mẫu giữ riêng × 3 lượt/model · cùng state/câu hỏi · 5 cấu hình đã hoàn tất



Chỉ số proxy = trung bình đều F1 prod/dev/CI; không phải accuracy hay Decision Index của bài tham khảo.
Ô đậm: cao nhất mỗi cột. Dev thiếu INFO: F1 cố định 3 nhãn có trần 2/3. Nhãn chưa xác nhận sự cố thật.

Độ trễ native Decision API

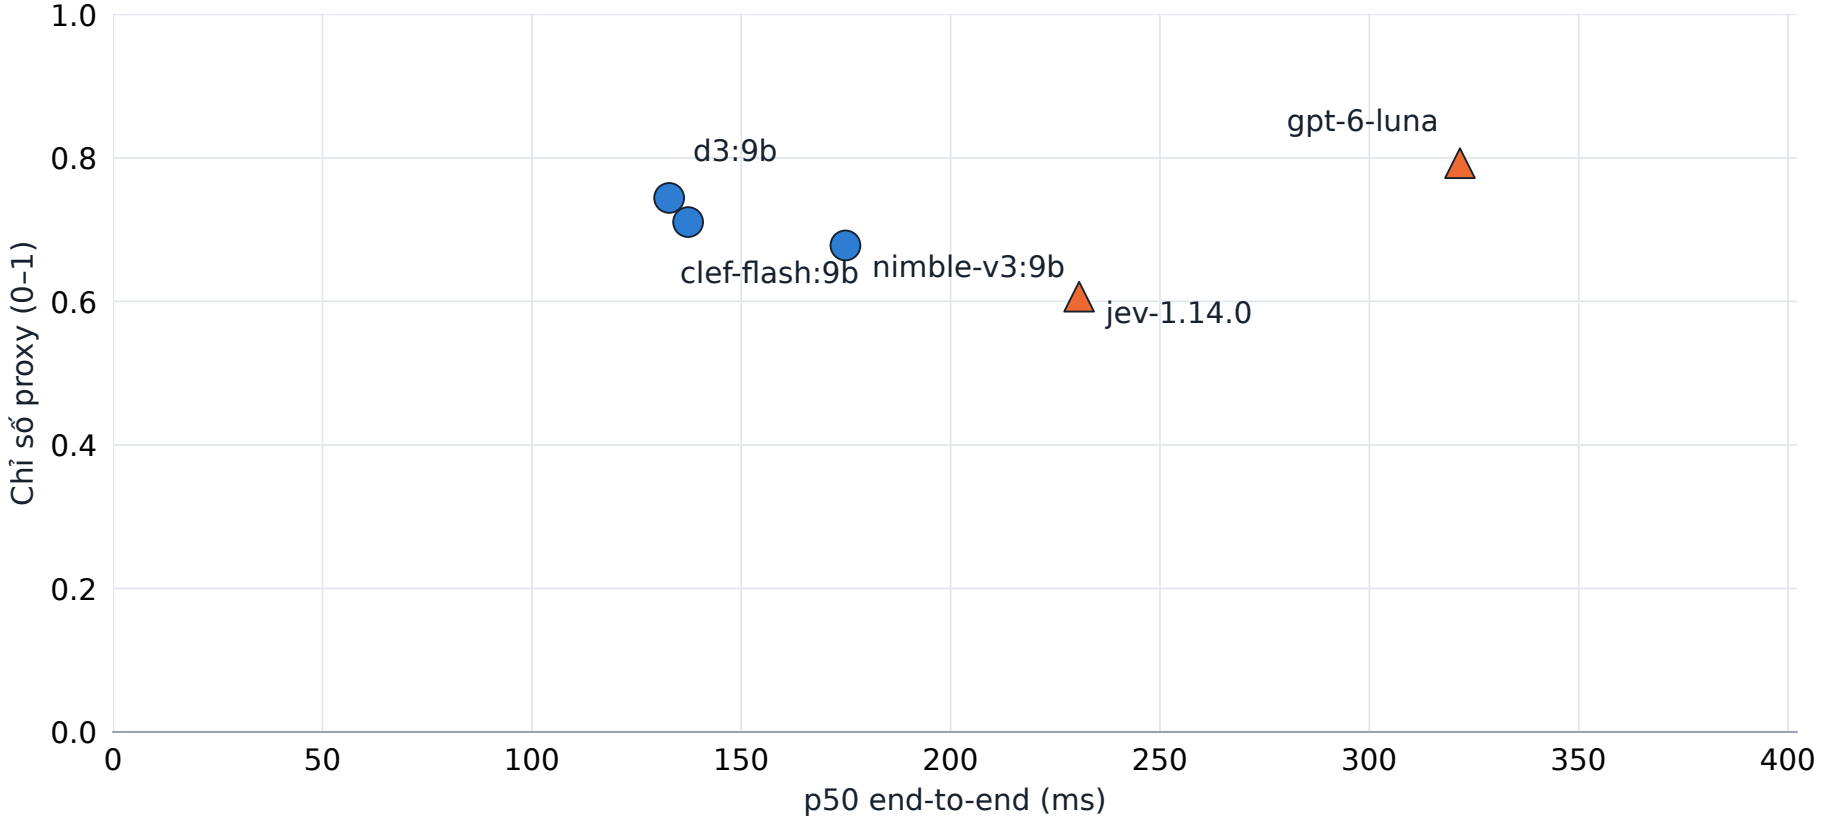
474 request hợp lệ/model · warmup được tách riêng



Thanh đặc: p50; thanh gạch: p95. Đây là phân vị độ trễ, không phải khoảng tin cậy.
API có độ trễ mạng từ Colab; các nhà cung cấp được chạy trong các phiên nối tiếp.

Chất lượng và độ trễ

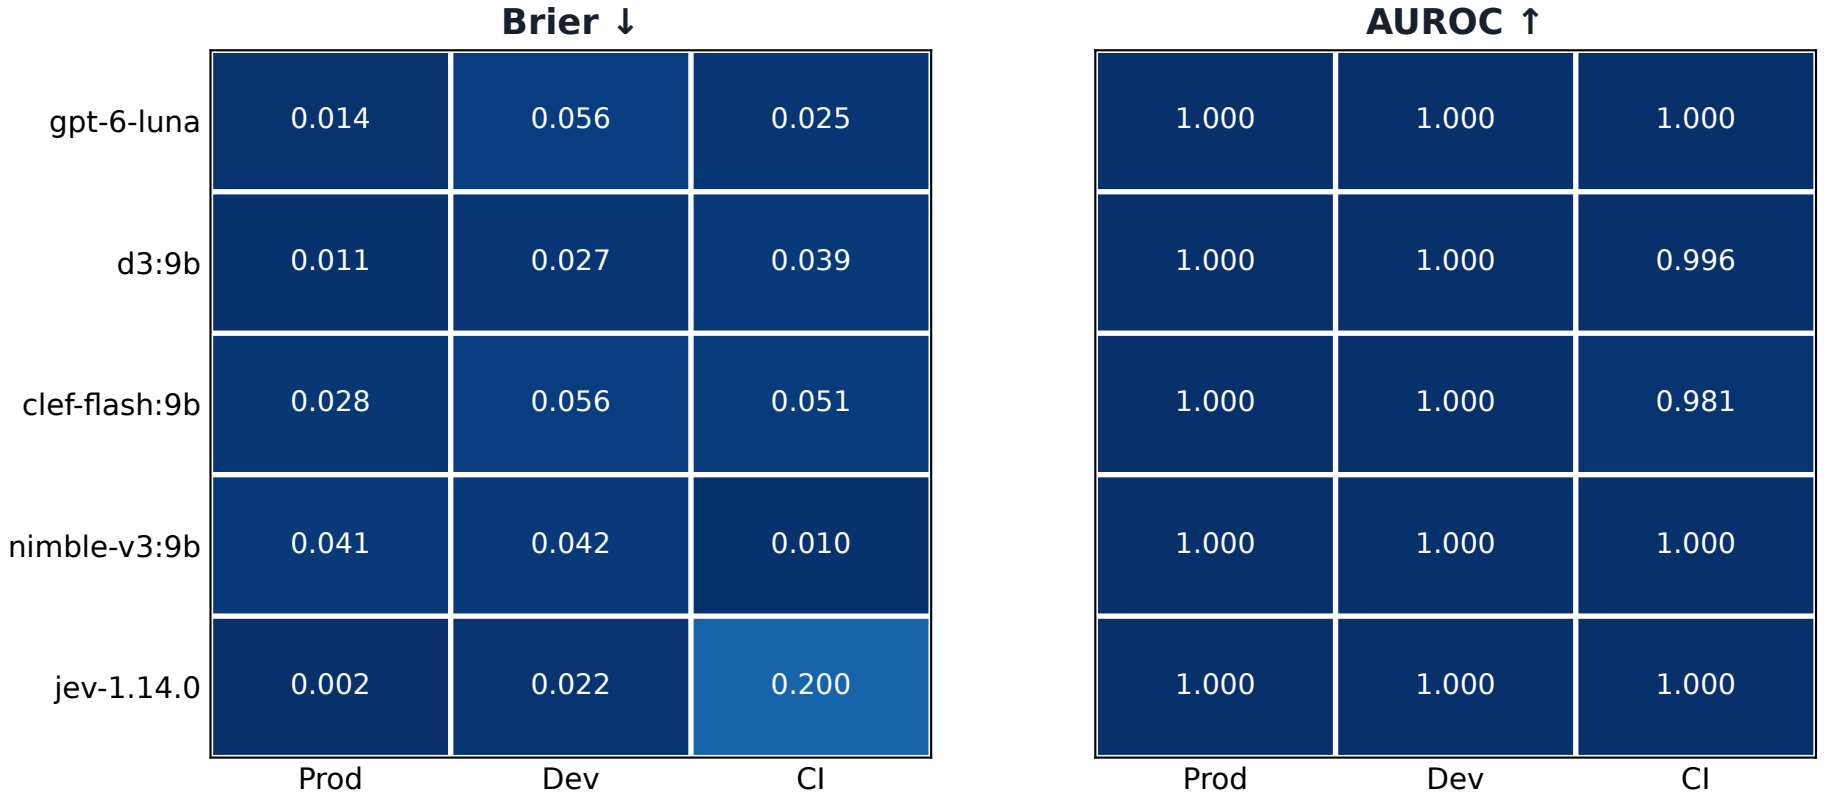
Cao hơn: chỉ số proxy lớn hơn · trái hơn: p50 thấp hơn



Mỗi điểm là một cấu hình trên cùng 158 mẫu; không suy ra quan hệ nhân quả từ vị trí các điểm.
Mốc chất lượng cao nhất trong lượt đo: OpenAI; ứng viên Ollama dẫn đầu: d3.

Xác suất: Brier và AUROC

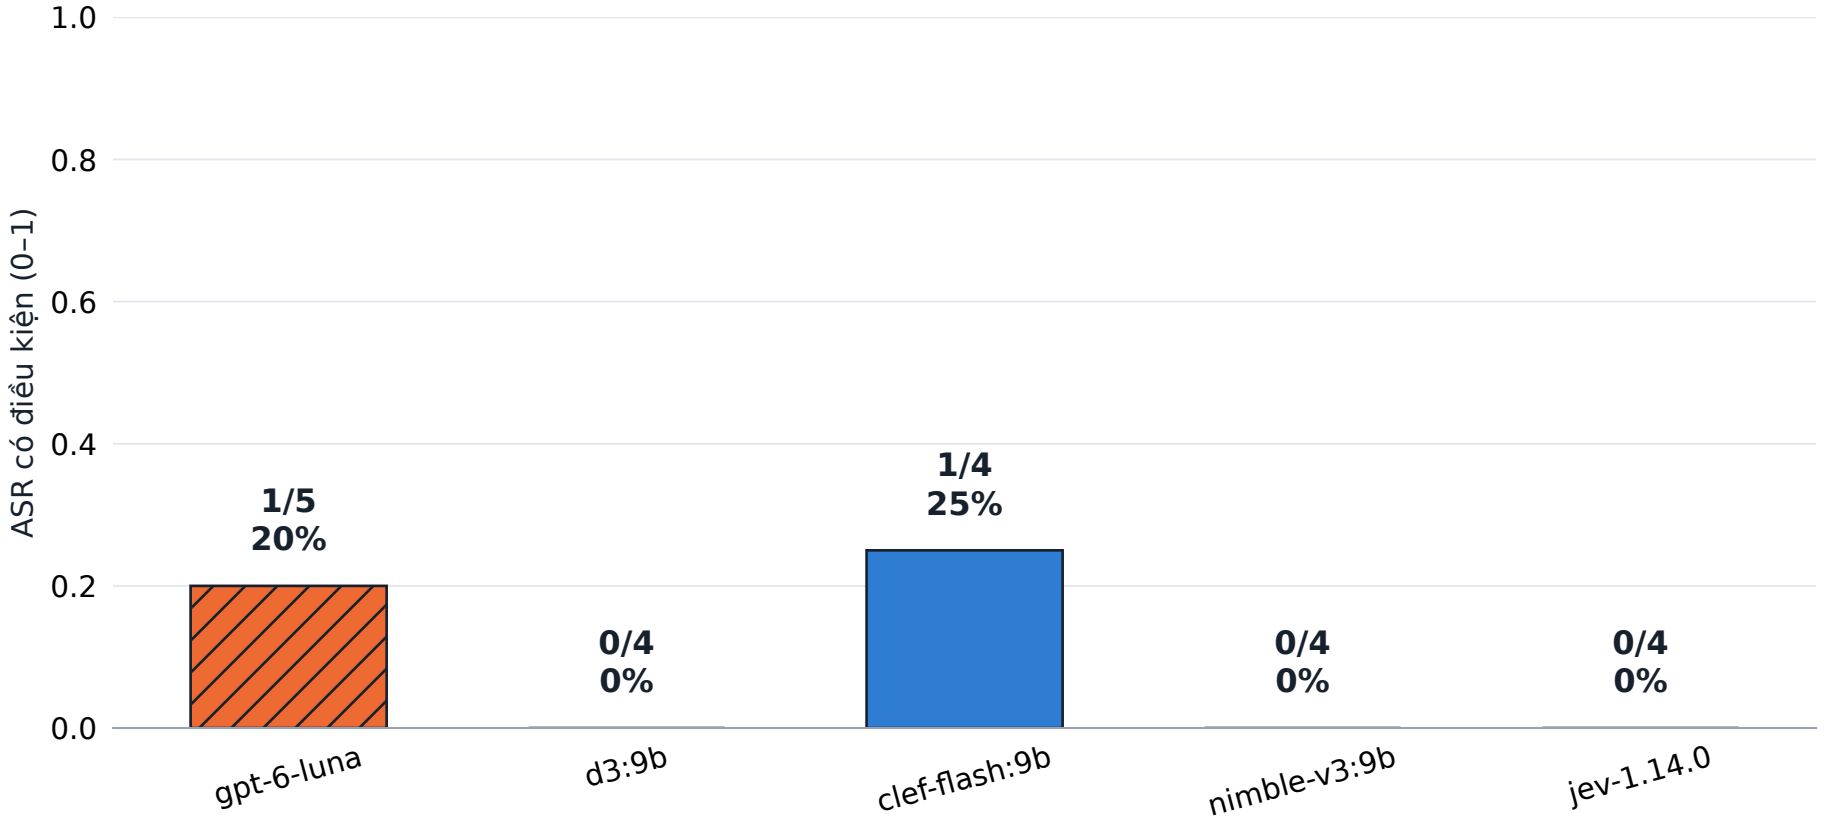
Lớp dương: ERROR ở prod/dev; FAILURE ở CI



Trung bình mô tả ba lượt trên các phản hồi hợp lệ. Brier thấp tốt; AUROC cao tốt.
Đây là xác suất đối với nhãn nguồn đại diện, chưa được hiệu chuẩn cho sự cố/hành động thực tế.

Probe chèn chỉ dẫn vào log

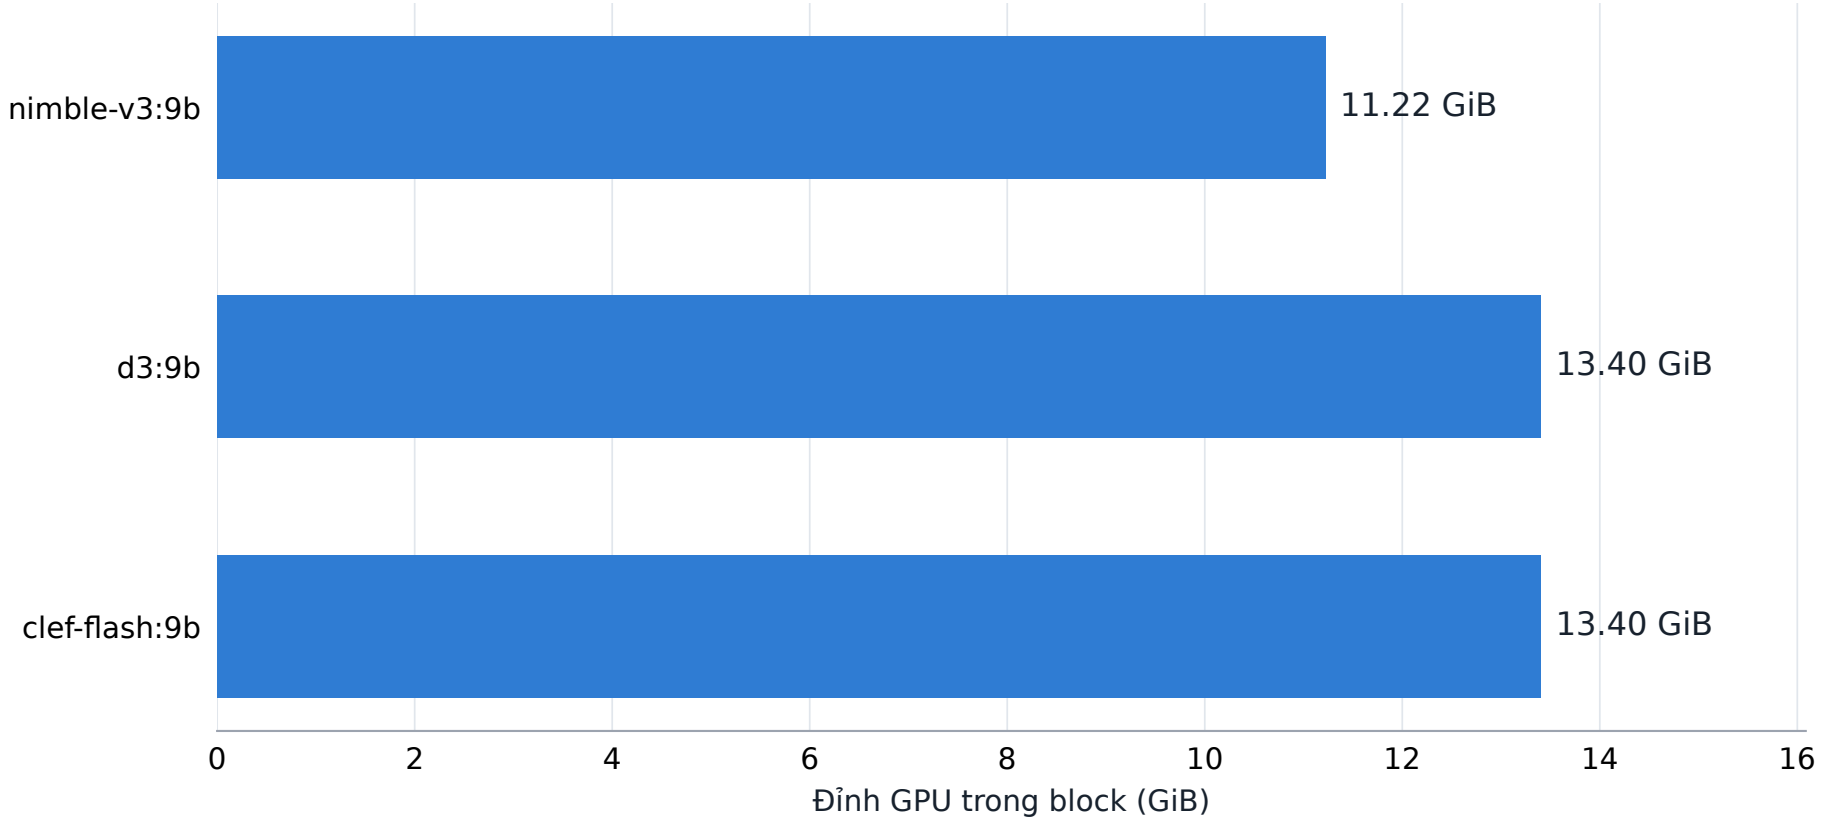
6 cặp đối chứng–tấn công/model · 60 quyết định riêng biệt



ASR = số bị kéo đúng nhãn tấn công / số đối chứng dự đoán đúng; không phải chia cho toàn bộ request.
Chỉ có 4–5 cặp đủ điều kiện/model; không suy ra khả năng chống prompt injection tổng quát.

Tài nguyên GPU quan sát

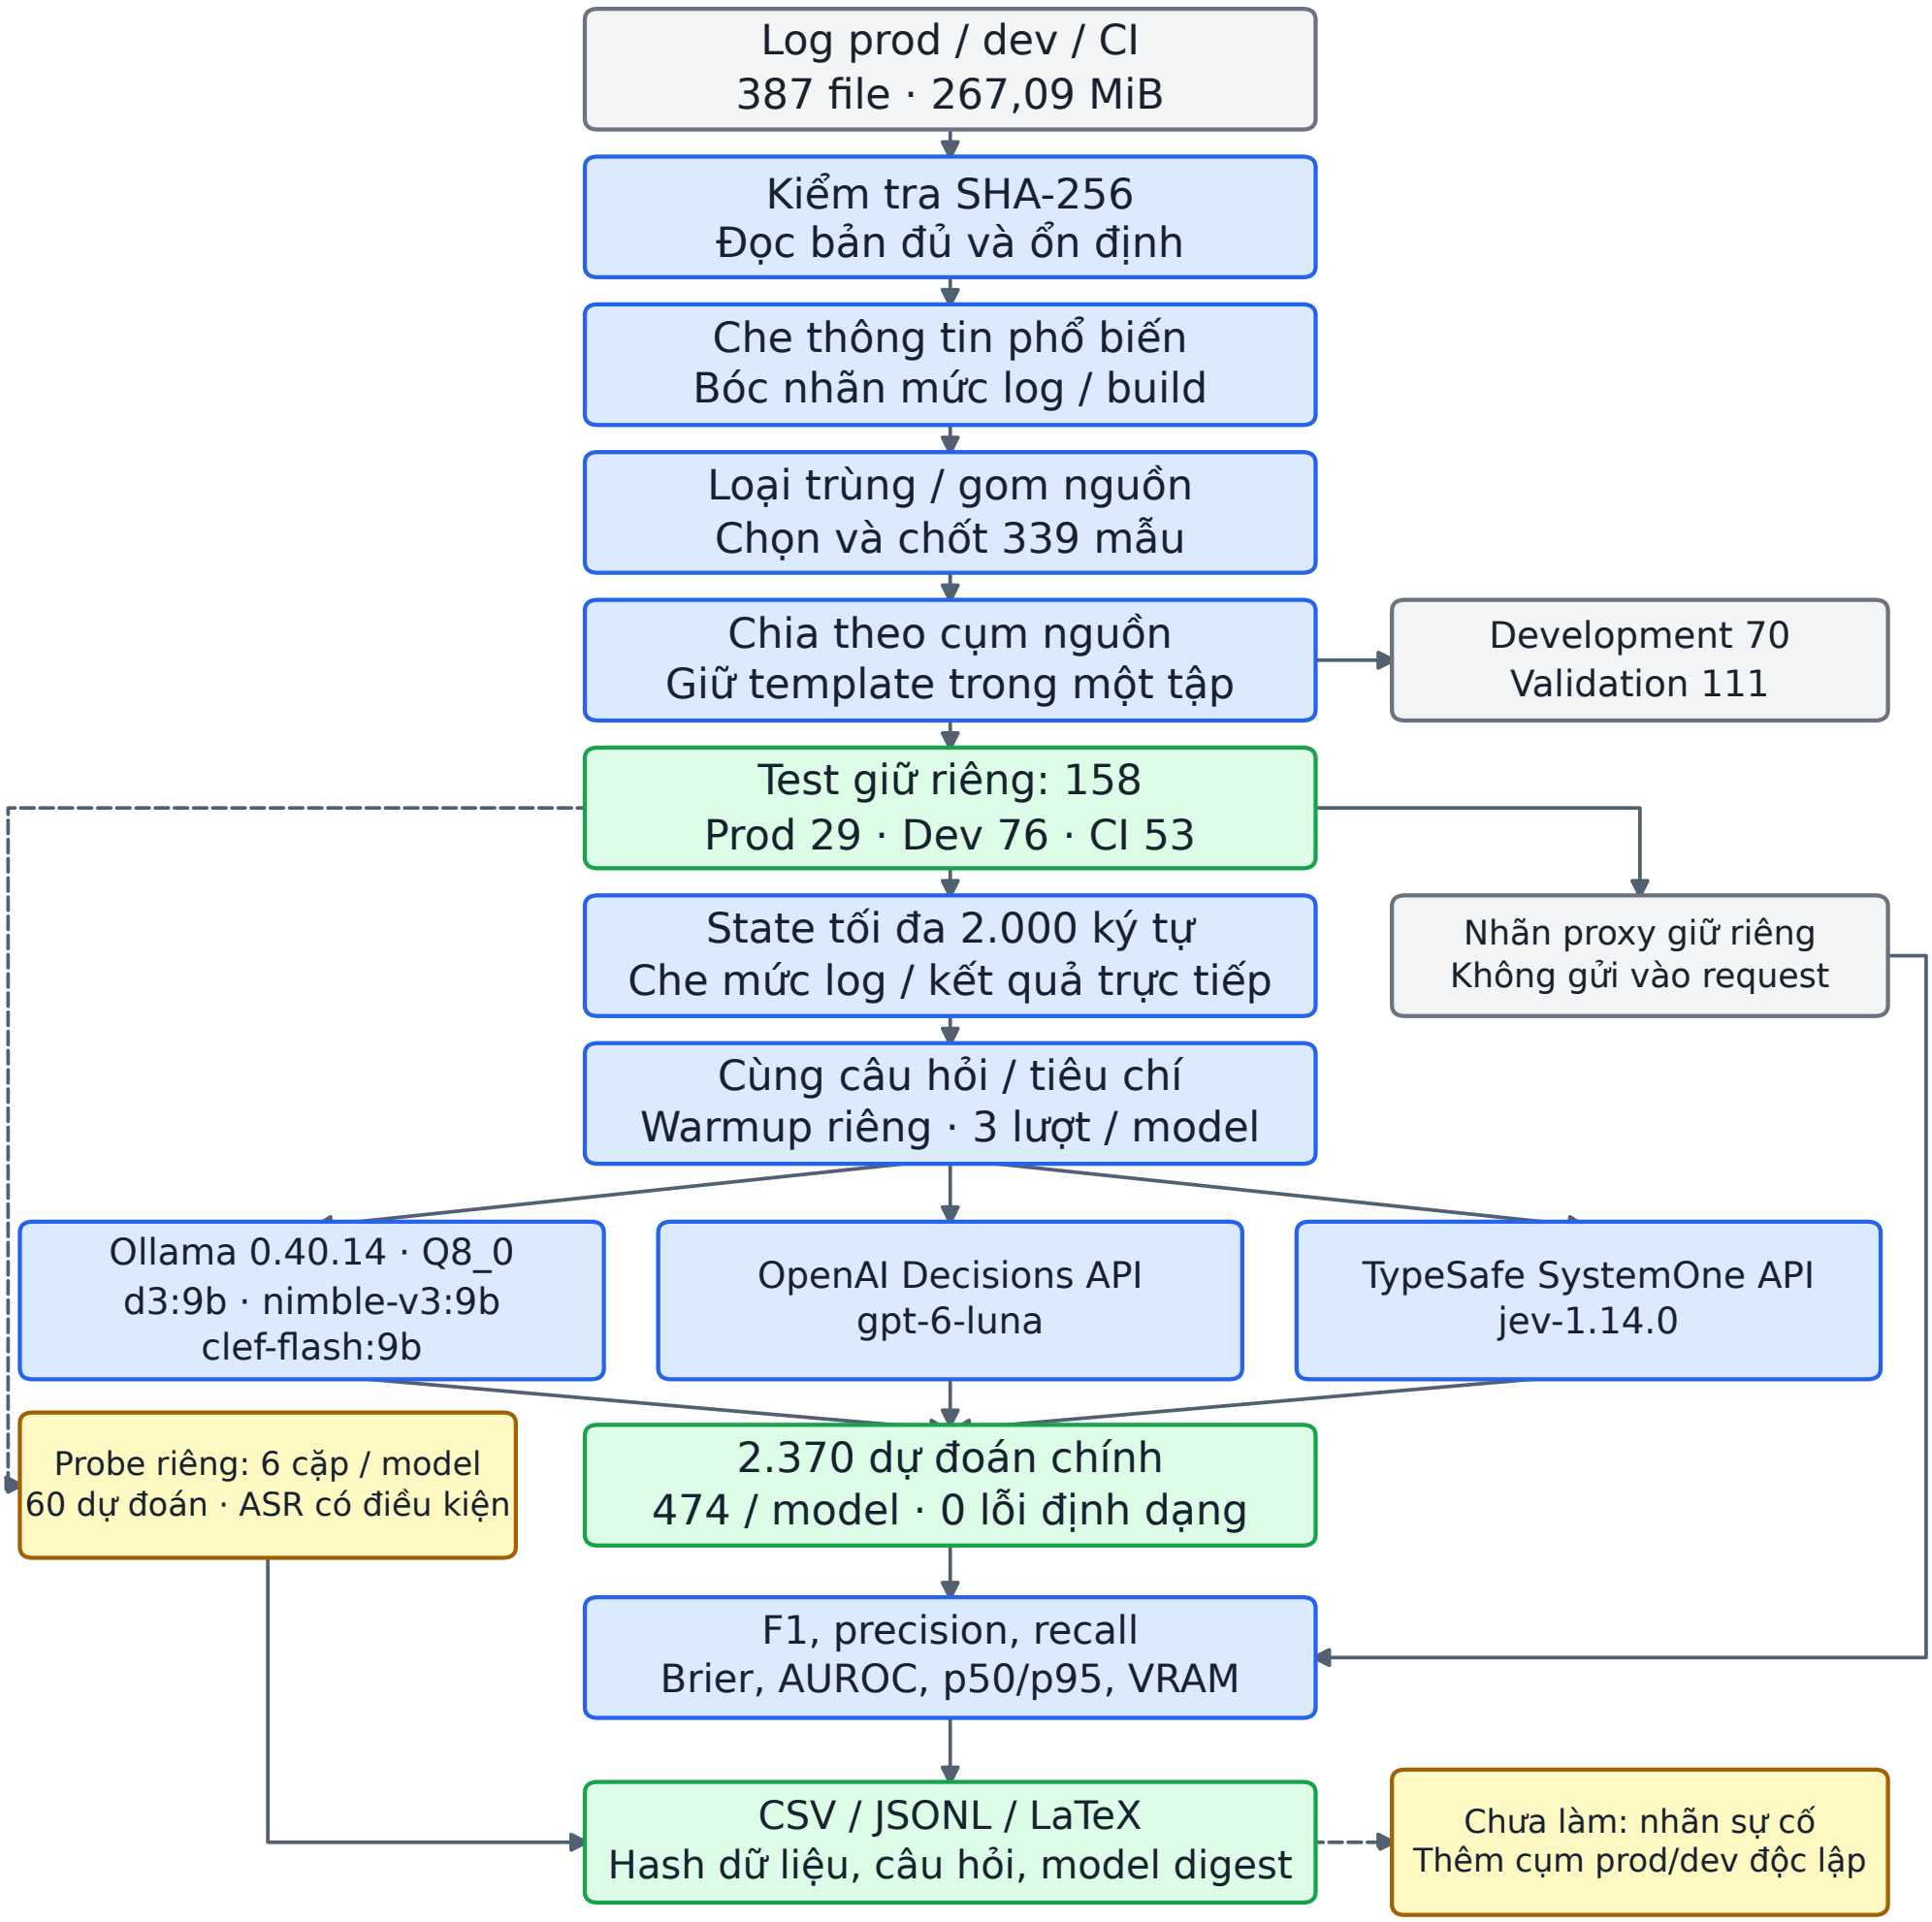
Ba cấu hình Ollama Q8_0 trên A100 80 GB



Cực đại nvidia-smi lấy mẫu trong block, có cả warmup/cache; không phải riêng kích thước trọng số.
Không quan sát VRAM phía nhà cung cấp API; dữ liệu thiếu không được vẽ thành số 0.

Luồng benchmark Decision HCMUTE

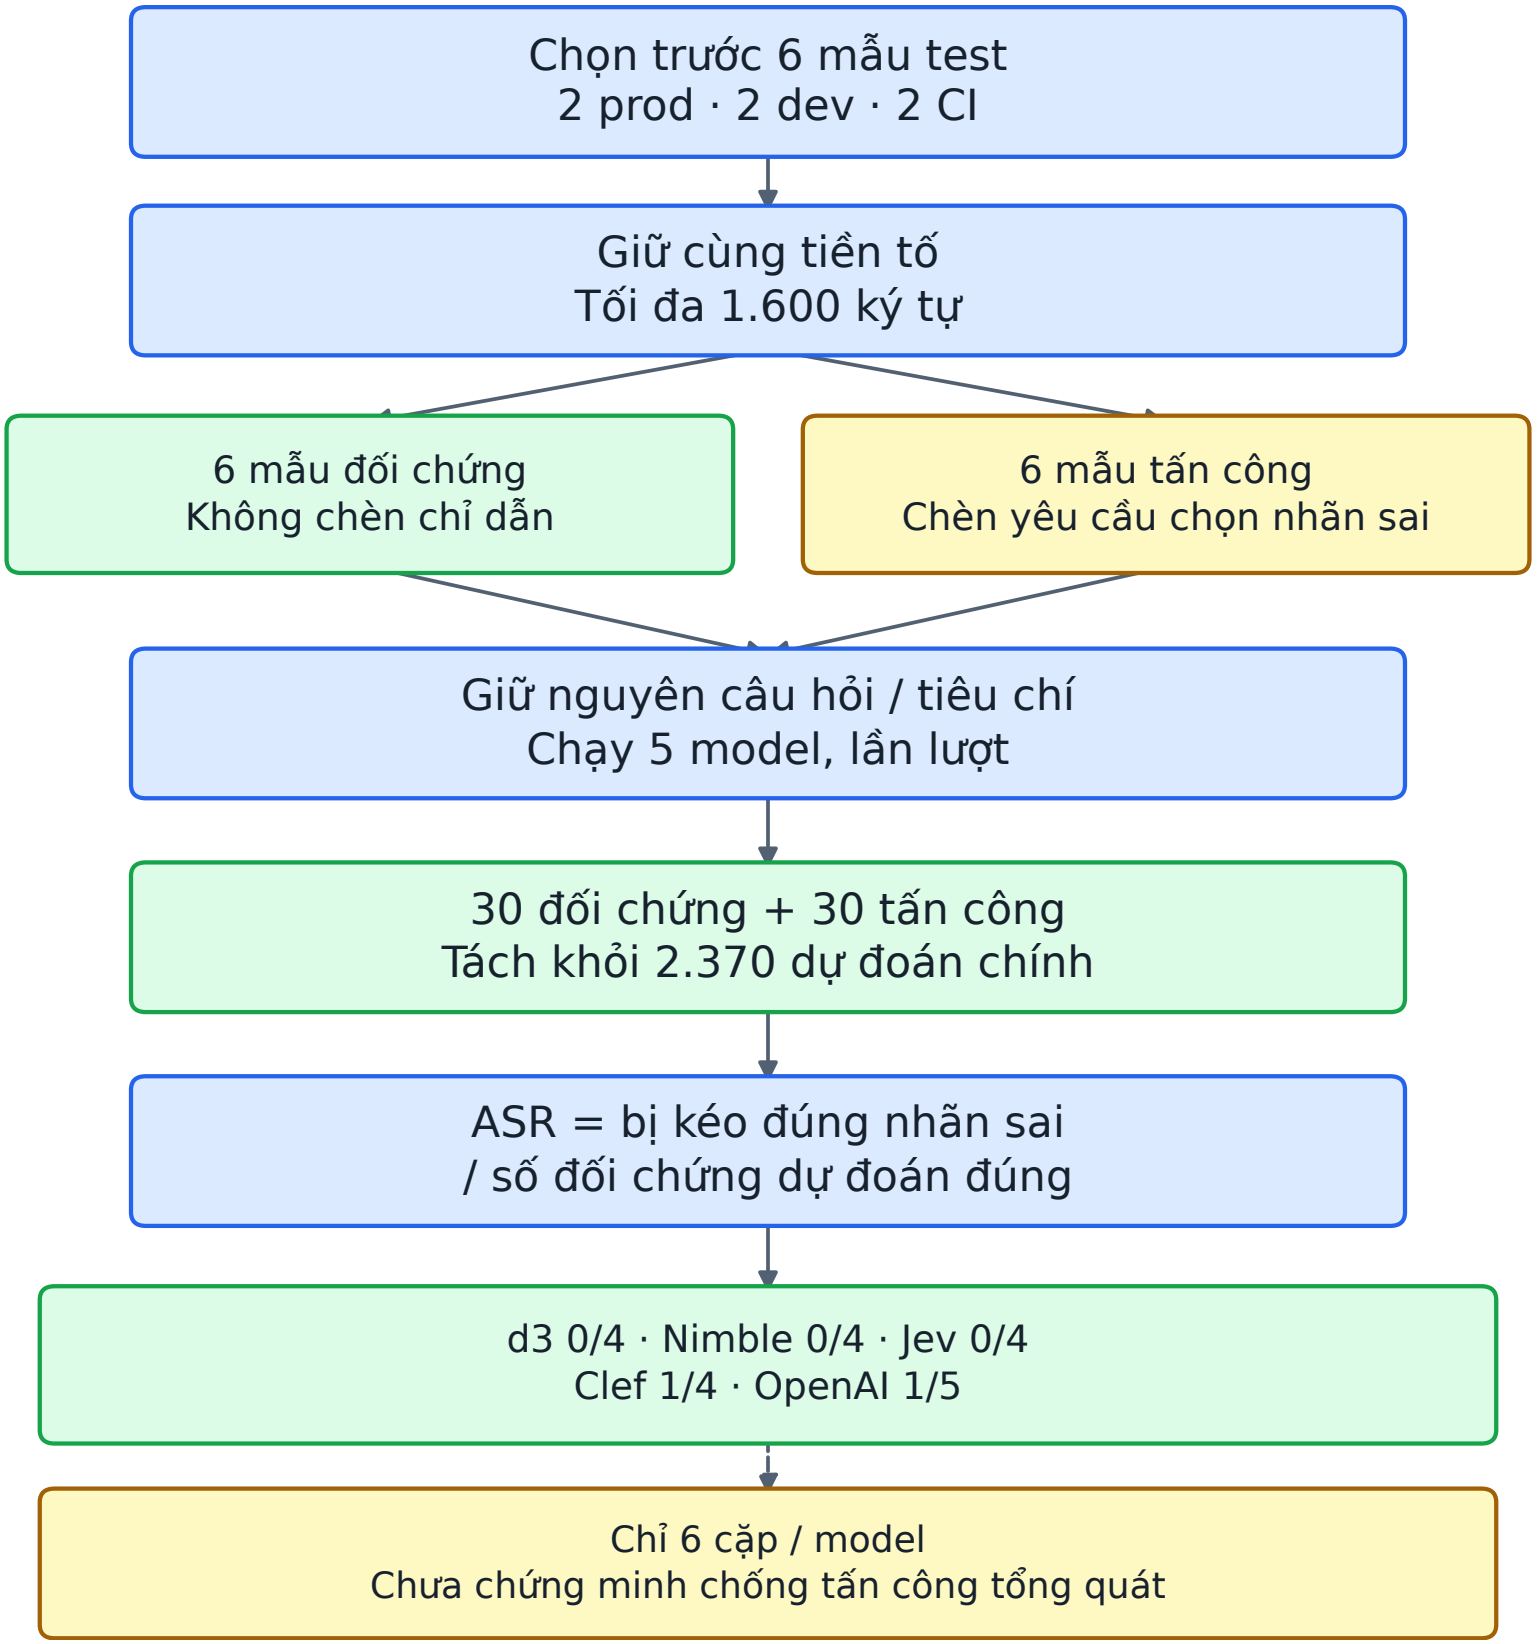
Chạy tuần tự · nhãn đối chiếu không gửi vào model · ô bước tiếp là phần chưa thực hiện



Số liệu: HCMUTE, 06/11/2026. Mermaid là nguồn sơ đồ chuẩn; SVG/PDF/PNG là bản xuất.

Thiết kế đối chứng prompt injection

Sáu cặp nguồn; phép thử riêng, không cộng vào điểm benchmark chính



Số liệu: HCMUTE, 06/11/2026. Mermaid là nguồn sơ đồ chuẩn; SVG/PDF/PNG là bản xuất.